

lsmeas: una estrategia de selección de variables para solvers Branch & Bound por intervalos

I. Araya, B. Neveu — *Journal of Global Optimization*, 2018

Presentación del artículo

September 26, 2026

Contexto: optimización global continua por intervalos

Problema (NCOP)

$$\min_{x \in \mathbf{x}} f(x) \quad \text{s.a.} \quad g(x) \leq 0, \quad f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad g : \mathbb{R}^n \rightarrow \mathbb{R}^m \text{ no convexas}$$

$x = x_1 \times \cdots \times x_n$ es una *caja* (producto de intervalos).

Branch & Bound por intervalos (Alg. 1) — se agrega la variable $x_0 = f(x)$

- **Selección de nodo:** caja de L (p.ej. minLB o FeasibleDiving).
- **Bisección:** partir la caja en dos por el punto medio de *una* variable.
- **Filtrado** (contractores: HC4, ACID, relajaciones lineales) $\Rightarrow$ cota inferior $\underline{x}_0$.
- **Upper bounding:** búsqueda de puntos factibles $\Rightarrow$ actualiza UB .
- Termina cuando $UB - LB \leq \varepsilon$.

Pregunta del paper: ¿qué variable conviene bisecar?

Sin información del sistema

- round-robin (rr): cicla $i \rightarrow (i + 1) \bmod n$. Sensible al orden inicial.
- largest-first (lf): mayor $\text{wid}(x_i)$.
Supone que dominios grandes impactan más.

Basadas en smear (Kearfott; Hansen & Walster)

$$\text{smear}(x_i, g_j) = |a_{ji}| \cdot \text{wid}(x_i)$$

a_{ji} : sobreestimación por intervalos de $\partial g_j / \partial x_i$ en x (diferenciación automática).

Estima (Taylor 1er orden) cuánto se reduce la imagen de g_j al reducir el dominio de x_i .

Agregaciones del valor smear y su limitación

$$\text{smearmax} : \arg \max_i \max_j \text{smear}(x_i, g_j)$$

$$\text{smearsum} : \arg \max_i \sum_j \text{smear}(x_i, g_j)$$

$$\text{smearsumrel} : \arg \max_i \sum_j \frac{\text{smear}(x_i, g_j)}{\sum_k \text{smear}(x_k, g_j)}$$

(La función objetivo se incluye en g .)

Problema

Todas las restricciones pesan igual, incluso las *inactivas* en el óptimo, que no influyen en la solución.

Trabajo relacionado: ViolationTransfer (Tawarmalani & Sahinidis, 2004)

- Usa el Lagrangiano de una *relajación convexa* y su solución óptima x^* .
- Define para cada variable un intervalo $x_i^v \subset x_i$ (caja mínima que contiene x^* y mantiene factible cada restricción univariada).
- Con relajación lineal $\min \sum c_i x_i$ s.a. $\sum_j a_{ji} x_i \leq 0$, el impacto estimado es

$$(\overline{x_i^v} - \underline{x_i^v}) \cdot \left| c_i + \sum_j \lambda_j^* a_{ji} \right|,$$

con λ^* el dual óptimo de la relajación.

Diferencias de 1smear: (1) linealización simple en vez de relajación convexa sofisticada; (2) mide impacto en el Lagrangiano del problema *original*; (3) usa x directamente en lugar de x^v (no requiere reformular el problema).

Multiplicadores de Lagrange óptimos

Lagrangiano y dual

$$L(x, \lambda) = f(x) + \sum_{j=1}^m \lambda_j g_j(x), \quad h(\lambda) = \inf_{x \in \mathbf{x}} L(x, \lambda), \quad \max_{\lambda \geq 0} h(\lambda)$$

- $h(\lambda) \leq f(x^*)$ para todo $\lambda \geq 0$ (dualidad débil).
- λ_j^* estima la tasa de cambio del óptimo ante cambios en g_j .
- $\lambda_j^* = 0$ para restricciones inactivas $\Rightarrow$ ponderación natural.

Caso lineal

$$\min_x c^T x \text{ s.a. } Ax \leq b \quad \Longleftrightarrow \quad \max_{\lambda} -b^T \lambda \text{ s.a. } A^T \lambda + c = 0, \lambda \geq 0$$

Fase 1 — Linealización + LP

$$g_j^l(x) = g_j(\text{mid}(x)) + \sum_{i=1}^n \text{mid}(J_{ji}) (x_i - \text{mid}(x_i))$$

- Se agregan las cotas $\underline{x}_i \leq x_i \leq \overline{x}_i$, $x_o = [-\infty, \infty]$.
- Se resuelve con simplex (SoPlex) $\Rightarrow$ dual óptimo λ^* .
- Si es infactible o no acotado $\Rightarrow$ smearsum.

Fase 2 — Smear del Lagrangiano

$$\mathcal{L}(x) = x_o + \sum_{j=1}^m \lambda_j^* g_j(x)$$

- Un solo “objetivo” que aproxima el problema completo.
- Se elige $\arg \max_i \text{smear}(x_i, \mathcal{L})$.
- Sin restricciones, coincide con cualquier estrategia smear.

Algoritmo lsmeas

Input: caja x , Jacobiano por intervalos J , restricciones g

Output: variable a bisecar

```
1  $g^I \leftarrow g(\text{mid}(x)) + \text{mid}(J) \cdot (x - \text{mid}(x));$ 
2  $x_o \leftarrow [-\infty, \infty];$ 
3  $(x_o, \lambda^t) \leftarrow \text{optimize}(\min x_o \text{ s.a. } \underline{x}_i \leq x_i \leq \overline{x}_i, g_j^I(x) \leq 0);$ 
4 if  $x_o \neq \emptyset$  then
5      $\lambda^* \leftarrow \lambda^t; \max\_impact \leftarrow 0;$ 
6     for  $i \in \{1..n\}$  do
7          $D \leftarrow \lambda_i^* ;$  // dual de la cota de  $x_i$ 
8         for  $j \in \{1..m\}$  do
9              $D \leftarrow D + \lambda_{n+j}^* J_{ji};$ 
10            if  $|D \cdot \text{wid}(x_i)| > \max\_impact$  then
11                 $\max\_impact \leftarrow |D \cdot \text{wid}(x_i)|; \text{var} \leftarrow i;$ 
12 return  $\text{var};$ 
13 else
14     return  $\text{smearsum}(x, J);$ 
```

Variante	Origen de λ^*	Función para el impacto	¿Modifica contractor?
lsmeas	linealización (mid del Jacobiano)	Lagrangiano original	No
lsmeas-MG	linealización (gradiente en mid)	Lagrangiano original	No
lsmeas-LI	linealización	Lagrangiano <i>linealizado</i>	No
lsmeas-LR	relajación lineal (X-Taylor + AF2)	Lagrangiano original	Sí
lsmeas-LRI	relajación lineal	Lagrangiano de la relajación	Sí

- **MG**: calcula dos gradientes (uno puntual, uno por intervalos).
- **LI**: reemplaza J_{ji} por $\text{mid}(J_{ji})$ en la Fase 2.
- **LR/LRI**: λ^* se suma sobre las varias restricciones lineales que relajan cada g_j ; la variable se elige justo después del filtrado y se guarda en el nodo.
- lsmeas-LRI es la variante más cercana a ViolationTransfer.

Configuración experimental

- Implementación en **IbexOpt** (librería Ibex): contractores HC4, ACID(HC4), relajación AF2 + XNewton; upper bounding inHC4 e InnerPolytope; selección de nodo FeasibleDiving; $\varepsilon = 10^{-6}$.
- Hardware: PowerEdge T420, Intel Xeon 2.2 GHz, 8 GB RAM.
- **Instancias:** series 1 y 2 de COCONUT; 76 instancias resueltas por alguna estrategia entre 2 s y 7200 s.
- 5 ejecuciones por instancia; se descartan la mejor y la peor y se promedian las 3 restantes.
- Solo se bisecan variables con $\text{wid} > 10^{-7}$.

Métrica: ganancia relativa promedio de a sobre b ,

$$t_r(a, b, \pi) = \frac{t(a, \pi)}{t(a, \pi) + t(b, \pi)}, \quad \text{gain}(a, b) = \frac{\sum_{\pi} t_r(b, a, \pi)}{\sum_{\pi} t_r(a, b, \pi)}$$

y perfiles de desempeño (proporción de instancias resueltas en $\leq \text{factor} \times \text{mejor tiempo}$).

Resultados: `lsmeas` vs. estrategias clásicas

Ganancia relativa promedio de `lsmeas`

vs.	gain
round-robin	2.04
largest-first	2.48
smearmax	1.34
smearsum	1.30
smearsumrel	1.32

- `lf` es la peor; las tres smear son comparables entre sí.
- $\approx 90\%$ de las instancias las resuelve `lsmeas` en menos de $2\times$ el mejor tiempo.
- Caso extremo: instancia resuelta en ~ 2 s por `lsmeas` vs. ~ 4096 s por `smearsum`.
- El LP de `lsmeas` tiene sobrecosto despreciable: el contractor (X-Taylor/AF2) ya resuelve hasta $2n$ LPs por nodo.

`smearsum` se toma como referencia clásica en el resto de experimentos.

Resultados: variantes de lsmeat

Ganancia relativa de lsmeat-MG (la mejor) respecto a

	lsmeat	lsmeat-LR	lsmeat-LI	lsmeat-LRI	ssum-active	ssum
gain	1.07	1.05	2.25	1.43	1.42	1.43

- lsmeat, lsmeat-MG y lsmeat-LR: desempeño similar y el mejor del grupo. Tiempo total (76 inst.): 21 035 s / 19 181 s / 20 429 s.
- **LI y LRI** (impacto en el Lagrangiano de la relajación, no del original) son las peores.
- ssum-active (descartar inactivas sin ponderar) $\approx$ smearsum: detectar activas no basta, hay que *ponderar*.
- Se prefiere lsmeat-MG: levemente mejor y *no requiere modificar el contractor*.

Interacción con la estrategia de búsqueda

Comparación de smearsum, smearsumrel y lsmeas-MG bajo **minLB** y **FeasibleDiving**.

Búsqueda	ssum	ssr	MG	gain MG
minLB	59 274	76 392	29 136	2.03
FeasibleDiving	43 867	65 789	19 181	2.29

Tiempo total (s) sobre el conjunto; gain frente al mejor competidor.

- FeasibleDiving supera a minLB con cualquier selección de variable.
- lsmeas-MG supera a las smear clásicas con cualquier selección de nodo (gain 1.63 con minLB, 1.43 con FD vs. smearsum).
- lsmeas-MG + minLB es *incluso* algo mejor que smearsum + FeasibleDiving.

Conclusiones y trabajo futuro

Aportes

- `lsmeas`: smear sobre un Lagrangiano cuyos multiplicadores se obtienen resolviendo, con simplex, una linealización de Taylor del problema.
- Supera significativamente a todas las estrategias clásicas de bisección y a la variante tipo `ViolationTransfer` (`lsmeas-LRI`).
- Clave: tras obtener λ^* , medir el impacto en las *restricciones originales*, no en la relajación.
- No intrusivo: independiente del contractor de relajación convexa; no altera el esquema del solver.

Trabajo futuro

- Incorporar los errores de violación de restricciones (como `ViolationTransfer`).
- Evaluar si evitar bisecar variables que aparecen solo en restricciones lineales (donde la relajación ya es óptima) ayuda o perjudica indirectamente.