

lsmeear: selección de variables con multiplicadores de Lagrange

J Glob Optim (2017)

Ignacio Araya Bertrand Neveu

Elegir la variable impacta el árbol de búsqueda

NCOP y solver intervalar

Minimiza $f(x)$ sujeto a $g(x) \leq 0$; el solver trabaja con cajas x .

- La poda combina filtrado y acotación sobre cada caja.
- La bisección define el árbol de búsqueda y su crecimiento.
- La estrategia de branching influye en el rendimiento.

Limitación

Un round-robin con orden inicial malo puede degradar el rendimiento.

Heurísticas clásicas: selección de variables

round-robin

- No usa información del sistema.
- Recorre las variables en ciclo.

largest-first

- Elige la variable con mayor dominio.
- Supone mayor impacto para anchos grandes.

smear-based

- Usa derivadas y anchos para estimar el impacto.
- Selecciona la variable con mayor valor agregado.

Limitación clave

No pondera la importancia de cada restricción.

ViolationTransfer usa una relajación lineal

Familia smear

- `smearsum`, `smearmax` y `smearsumrel` agregan impactos locales.
- Buscan aproximar la influencia global de cada variable.
- `lsmear` conserva la intuición y usa una linealización simple.

Mensaje clave

`lsmear` evita una relajación convexa sofisticada y usa una aproximación lineal simple.

ViolationTransfer

- Trabaja con la función Lagrangiana de una relajación del problema.
- Pesa restricciones con multiplicadores duales óptimos.
- Estima qué variable puede mejorar más el problema.

lsmer usa duales para ponderar restricciones

Idea

- Linealiza cada $g_j(x)$ alrededor del punto medio de la caja.
- Resuelve el programa lineal aproximado y obtiene λ^* .
- Usa esos duales para ponderar la Lagrangiana aproximada.
- Selecciona la variable con mayor impacto en $L(x)$.

Mensaje clave

No pondera todas las restricciones igual: usa una estimación de su importancia dual.

Idea central

$$D_i = \lambda_i^* + \sum_j \lambda_{n+j}^* J_{ji}$$

$|D_i| \text{wid}(x_i)$ mide el impacto de cada variable.

- lsmeas estima multiplicadores de Lagrange óptimos.
- D_i combina la cota de la variable con las restricciones linealizadas.
- Si el LP falla o es no acotado, smearsum toma el relevo.
- La linealización del problema global produce una aproximación del problema original.

El algoritmo separa linealización y decisión

Input: caja actual x , Jacobiano intervalar J , restricciones g

Output: variable a bisectar

```
1 linearizar  $g_j(x)$  alrededor de  $\text{mid}(x)$ ;  
2 fijar la cota del objetivo como no acotada en el LP;  
3 resolver el LP con SoPlex y obtener  $\lambda^*$ ;  
4 if  $\lambda^* = \emptyset$  o el óptimo es no acotado then  
5   | return smearsum( $x, J$ );  
6 for  $i \in \{1, \dots, n\}$  do  
7   |  $D \leftarrow \lambda_i^*$ ;  
8   | for  $j \in \{1, \dots, m\}$  do  
9     |  $D \leftarrow D + \lambda_{n+j}^* J_{ji}$ ;  
10  | medir  $|D \text{ wid}(x_i)|$  y conservar el máximo;  
11 return la variable con mayor impacto;
```

Los experimentos usan Ibex0pt y COCONUT

- Ibex0pt implementa lsmear con contratos HC4, ACID y lineal.
- La búsqueda de cajas usa FeasibleDiving; $\epsilon = 10^{-6}$.
- Servidor PowerEdge T420: dos Xeon 2.20 GHz, 8 GB RAM.
- Se evaluaron 76 instancias de COCONUT.
- Cada estrategia se ejecutó cinco veces por instancia.

Ismeat supera a las heurísticas clásicas

Diapositiva pendiente de revisión

lsmear-MG es la variante preferida

Idea principal

- lsmear-MG lineariza con el gradiente en el punto medio.
- Su rendimiento es comparable al de lsmear-LR.

Limitación clave

- lsmear-LI y lsmear-LRI empeoran al usar la Lagrangiana lineal.
- ssum-active no mejora frente a ssum.

Instancia	lsmear	lsmear-MG	lsmear-LR
hs087	0.6	0.6	5.7
bearing	15	16	57
harker	1071	1514	3865
immun	9.3	8.6	5.0
linear	137	25	115
total time	21,035	19,181	20,429

La estrategia de búsqueda también importa

Diapositiva pendiente de revisión

lsmear supera a las estrategias clásicas

Resultado principal

- `lsmear` claramente supera a `rr`, `lf`, `ssum`, `smax` y `ssr`.
- `lsmear` resuelve casi 90% de las instancias en menos de dos veces el mejor tiempo.
- La sobrecarga de resolver el LP es *negligible* frente al contractor de poda.

Clave práctica

`lsmear-MG` es la variante preferida: rinde muy bien y no requiere modificar el contractor.

Futuro: integrar ViolationTransfer

Idea central

ViolationTransfer usaría errores de violación para ponderar variables.

Limitación pendiente

- Variables solo lineales: quizá no conviene bisectarlas.
- Los contractors lineales ya reducen óptimamente esos dominios.
- La bisección indirecta podría ayudar en restricciones no lineales.