

Ismeat: selección de variables para branch-and-bound intervalar

Journal of Global Optimization, 2017

Ignacio Araya Bertrand Neveu

El problema es elegir bien qué variable dividir

- Una mala elección de variable puede disparar el árbol de búsqueda.
- La bisectriz afecta **cota inferior**, factibilidad y número de cajas.
- `round-robin` ignora el sistema; `largest-first` mira solo el ancho.

Idea clave

La variable a dividir debe reflejar el impacto real en el problema, no solo el dominio.

Las heurísticas clásicas no distinguen restricciones activas

`smear` trata todas las restricciones igual

- `smearsum`, `smearmax` y `smearsumrel` agregan impactos sin ponderación.
- No distinguen restricciones activas e inactivas.

`ViolationTransfer` es más intrusiva

- Usa relajación convexa y la función de Lagrange.
- Requiere un problema reformulado para construir x_i^v .

La idea es ponderar con multiplicadores duales óptimos

Contexto y método

- **lsmeas** reusa una función smear tipo Lagrangiano para ponderar restricciones.
- Linealiza el problema alrededor del punto medio de la caja.
- Resuelve un programa lineal para estimar *optimal Lagrange multipliers*.
- Reemplaza los pesos del Lagrangiano por esa estimación dual.

Esquema de la aproximación

$$g_j(x) \approx g_j(\text{mid}(x)) + \text{mid}(J_{j:}) (x - \text{mid}(x))$$

La expansión de primer orden usa $\text{mid}(J_{j:})$ como sobreestimación intervalar.

lsmeas computa el impacto con un Lagrangiano

$$L(x, \lambda^*) = f(x) + \sum_{j=1}^m \lambda_j^* g_j(x)$$

- L pondera cada restricción con **multiplicadores duales óptimos**.
- $\lambda_j^* = 0$ para restricciones inactivas.

$$\text{impacto}_i = |D_i| \text{ wid}(x_i), \quad D_i = \lambda_i^* + \sum_{j=1}^m \lambda_{n+j}^* J_{ji}$$

- D_i agrega el efecto de la variable x_i en la linealización.
- Se bisecciona la variable con mayor impacto.

lsmeas linealiza y luego selecciona

Input: caja x

Output: variable i^*

- 1 linealizar f en el centro de x ;
 - 2 resolver el LP asociado;
 - 3 **if** el LP falla **then**
 - 4 | usar smearsum;
 - 5 calcular $s_i \leftarrow |D_i| \text{wid}(x_i)$;
 - 6 **return** $\arg \max_i s_i$;
-

Idea clave

La linealización de Taylor guía la selección de la variable más prometedora.

La evaluación usa IbexOpt y 76 instancias

Diapositiva pendiente de revisión

lsmeas reduce el tiempo total frente a clásicos

Comparación global

- Se comparó lsmeas con rr, lf, ssum, smax y ssr.
- En el total, lsmeas suma 21 035 s; smax, 29 136 s.
- Domina en casi 90% de las instancias.

Estrategia	Tiempo total (s)
lsmeas	21 035
smax	29 136
ssum	43 867
ssr	65 789
lf	144 477
rr	77 602

lsmeas-MG mejora aún más y simplifica implementación

Variante	Tiempo total (s)	Boxes	Gain
lsmeas	21 035	–	0.91
lsmeas-MG	19 181	–	1.07
lsmeas-LR	20 429	–	0.94
lsmeas-LI	–	–	–
lsmeas-LRI	–	–	–

- lsmeas-MG obtiene el mejor tiempo total y supera a lsmeas y lsmeas-LR.
- lsmeas-LI y lsmeas-LRI reportan los peores resultados.
- lsmeas-MG evita modificar el contractor del solver.

FeasibleDiving potencia más que minLB

Búsqueda	Tiempo total	Ganancia de lsmeas-MG
minLB	59,274	2.03
FeasibleDiving	43,867	2.29

- FeasibleDiving supera a minLB con cualquier selección de variables.
- lsmeas-MG con minLB aún vence a ssum con FeasibleDiving.
- En el total, FeasibleDiving reduce el tiempo agregado frente a minLB.

El sobrecoste de linearizar es pequeño

Mensaje clave

- `lsmeas` resuelve un LP extra con el mismo Jacobiano usado por `smearsum`.
- Ese costo es pequeño frente al filtrado del solver, que domina el tiempo total.

Variantes y limitación

- `lsmeas-LR` y `lsmeas-LRI` usan relajación lineal y requieren modificar el contractor.
- `lsmeas`, `lsmeas-LI` y `lsmeas-MG` evitan ese cambio con una linearización independiente.

La principal ganancia viene de ponderar restricciones

Idea central

- Ponderar restricciones con λ^* supera tratarlas como igualmente importantes.
- `lsmer-MG` es la variante más simple y eficaz.
- La relajación lineal completa no compensa su mayor complejidad.

Mensaje clave

Detectar restricciones activas no basta; hay que incorporarlas en la ponderación.

lsmeasr usa información dual para biseccionar

Idea del método

- Usa multiplicadores de Lagrange óptimos de una linealización.
- Calcula el `smeasr` sobre una función tipo Lagrangiano.
- Ignora variables ligadas solo a restricciones lineales.

Mensaje clave

La selección mejora al ponderar restricciones y variables con información dual e intervalar.

- Extiende la heurística a otros solvers intervalares y variantes híbridas.
- Incorpora errores de violación, como en `ViolationTransfer`.