

Contexto

- Optimización global continua y determinista mediante *branch and bound* intervalar.
- Problema: $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ sobre una caja.

Bisección

- Divide la caja actual en dos subcajas.
- Muchas estrategias usan información local para elegir la variable.
- Una mala ordenación inicial puede degradar el rendimiento.

El criterio smear clásico ignora pesos de restricciones

- `round-robin` no usa información del sistema.
- `largest-first` ignora la estructura de derivadas.
- `smearsum`, `smearmax` y `smearsumrel` tratan todas las restricciones por igual.
- `ViolationTransfer` pondera restricciones, pero exige relajación convexa intrusiva.

El solver estándar alterna poda y bifurcación

Estructura básica

- Selecciona una caja activa, la bisecciona y filtra cada subcaja.
- **Poda**: actualiza la cota inferior con `contractors` sobre x_o .
- **Upper bounding**: busca soluciones factibles y mejora UB y x_{UB} .

Cuello de botella

La calidad de la variable de bisección domina el tamaño del árbol.

lsmeas pondera restricciones con duales lineales

Idea del método

- Linealiza cada $g_j(x)$ con Taylor de primer orden alrededor del centro de la caja.
- Resuelve un problema lineal con cotas de caja mediante `simplex`.
- Usa **multiplicadores duales óptimos** para ponderar el Lagrangiano aproximado.

Si el LP falla

Si no hay solución óptima o el valor es no acotado, lsmeas cae a `smearsum`.

La variante básica usa dos fases

Idea del método

- Fase 1: linealiza cada restricción alrededor del punto medio de la caja.
- Fase 2: mide el impacto variable por variable en el Lagrangiano.
- Los multiplicadores de la relajación lineal reemplazan a los del problema original.

$$g_j(x) \approx g_j(\text{mid}(x)) + J_j(\text{mid}(x))^T (x - \text{mid}(x))$$

La restricción se aproxima con el término lineal de Taylor en el centro de la caja.

$$L(x, \lambda^*) = f(x) + \sum_{j=1}^m \lambda_j^* g_j(x)$$

Los pesos λ^* provienen del problema lineal y estiman la importancia de cada restricción.

La selección maximiza un smear ponderado

Idea central

$$D_i = \lambda_i^* + \sum_{j=1}^m \lambda_{n+j}^* J_{ji}$$

$$\text{impacto}(x_i) = |D_i| \text{ wid}(x_i)$$

- `lsmeas` usa multiplicadores duales óptimos para ponderar restricciones.
- J_{ji} aproxima $\partial g_j / \partial x_i$ con derivadas intervalares.
- El impacto combina sensibilidad y ancho del intervalo de x_i .
- Se elige la variable con **mayor magnitud de impacto**.

Limitación y fallback

Si el programa lineal no tiene solución o es no acotado, se usa `smearsum`.

lsmeas en dos fases

Idea

La estrategia usa una **estimación de multiplicadores duales óptimos** para ponderar las restricciones.

Input: caja x , Jacobiano intervalar J , restricciones g

Output: variable a biseccionar

```
1 linealizar  $g$  en torno a  $\text{mid}(x)$ ;  
2 resolver el LP con la cota del objetivo no acotada;  
3 if el LP no tiene solución o es no acotado then  
4   return  $\text{smeasum}(x, J)$ ;  
5 for  $i \in 1, \dots, n$  do  
6    $D \leftarrow \lambda_i^*$ ;  
7   for  $j \in 1, \dots, m$  do  
8      $D \leftarrow D + \lambda_{n+j}^* J_{ji}$ ;  
9   evaluar  $|D \cdot \text{wid}(x_i)|$ ;  
10 return la variable con mayor impacto;
```

Implementación

Se usa SoPlex para resolver el problema primal y el dual.

Cuatro variantes aíslan el efecto de cada decisión

Linealización

- `lsmear-MG` usa el gradiente en el punto medio.
- `lsmear-LI` reemplaza J_{ji} por su media en el lagrangiano.
- Ambas conservan una estimación local y barata.

Relajación

- `lsmear-LR` obtiene λ^* desde una relajación lineal.
- `lsmear-LRI` combina esa relajación con el impacto lineal.
- Aíslan el efecto de la linealización y de los multiplicadores.

Configuración experimental

- IbexOpt integra HC4, ACID, AF2, XNewton, inHC4 e InnerPolytope.
- Se evaluaron 76 instancias de COCONUT en cinco ejecuciones por estrategia.
- Se reporta el promedio de las tres ejecuciones centrales.
- La precisión objetivo fue $\epsilon = 10^{-6}$.

Criterio de timeout

timeout indica no resolver la instancia en 7200 s en ninguna de las tres ejecuciones.

lsmeas supera a las estrategias clásicas

Comparación global

- Se comparó con `rr`, `lf`, `smearsum`, `smearmax` y `smearsumrel`.
- `lf` obtuvo los peores resultados; `smearsum`, `smearmax` y `smearsumrel` rindieron de forma similar.
- `lsmeas` superó claramente a las estrategias clásicas.

Ventaja media relativa

$$\text{gain} = \frac{\text{best classical time}}{\text{lsmeas time}}$$

Razón entre el mejor tiempo clásico y el tiempo de `lsmeas` en cada instancia.

2.04 (`rr`), 2.48 (`lf`), 1.34 (`smearmax`), 1.30 (`smearsum`), 1.32 (`smearsumrel`)

Promedios reportados; `smearsum` es la mejor estrategia clásica.

lsmeas-MG es la mejor variante y la más simple

Lectura principal

- lsmeas-MG, lsmeas-LR y lsmeas muestran el mejor desempeño.
- lsmeas-LI y lsmeas-LRI reportan los peores resultados.
- lsmeas-MG se prefiere por su implementación más simple.

Variante	Ganancia	Lectura
lsmeas-MG	1.07	mejor global
lsmeas-LR	1.05	muy cercana
lsmeas-LI	2.25	peor desempeño
lsmeas-LRI	1.43	peor desempeño
ssum-active	1.42	sin mejora clara
ssum	1.43	referencia

ssum-active no mejora

- Detectar restricciones activas sin ponderarlas no mejora frente a ssum.

FeasibleDiving potencia a lsmeas-MG

Estrategia	smearsum	smearsumrel	lsmeas-MG	Ganancia
minLB	76 392	29 136	2.03	1.63
FeasibleDiving	65 789	19 181	2.29	1.43

- FeasibleDiving domina a minLB en todas las selecciones de variable.
- lsmeas-MG vence a smearsum y smearsumrel con ambos buscadores.
- La mejor combinación es lsmeas-MG con FeasibleDiving.

lsmear supera las estrategias clásicas

Contexto y problema

- lsmear es una nueva estrategia de selección de variables para `interval-based solvers`.
- Pondera restricciones con multiplicadores de Lagrange óptimos.

Idea del método

- La `linealización` del problema calcula los multiplicadores con el método simplex.
- lsmear define una función tipo Lagrangiano y mide su valor de smear.
- lsmear-MG calcula los impactos con las restricciones originales.

Resultado principal y trabajo futuro

- lsmear y lsmear-MG superan significativamente a las estrategias clásicas de bisección.
- lsmear es independiente del contractor basado en relajación convexa.
- Futuro: incorporar errores de violación para ponderar variables relacionadas.