

lsmeas: selección de variables con multiplicadores lagrangianos

Journal of Global Optimization

Ignacio Araya Bertrand Neveu

Elegir mal la variable multiplica nodos

Contexto

La optimización global continua se resuelve determinísticamente con *branch and bound* por intervalos.

Problema

La bisección depende de elegir bien la variable; una mala elección multiplica nodos y tiempo.

Estrategias clásicas

- round-robin: no usa información del sistema.
- largest-first: elige la variable con mayor dominio.
- smear-based: agrega impactos de todas las restricciones.

Idea de lsmeas

$$D_i = \sum_{j=1}^m \lambda_j^* \text{wid}(x_i) \max(|J_{ji}|)$$

La variable se elige por su impacto ponderado en la función de Lagrange.

Limitación común

Tratan todas las restricciones como igualmente importantes.

lsmeas evita la intrusión de ViolationTransfer

Idea común

- Ambos usan multipliers duales y una función Lagrangiana.
- Seleccionan la variable con mayor impacto estimado.

Limitación de ViolationTransfer

- Requiere reformular la relajación convexa.
- Modifica el contractor y la estrategia del solver.

lsmeas: alternativa simple

- Usa una linealización de Taylor del problema original.
- Calcula el impacto sin tocar el contractor.

lsmeas pondera restricciones con multiplicadores óptimos

Idea del método

$$g_j(x) \approx g_j(\text{mid}(x)) + \text{mid}(J_{j.}) (x - \text{mid}(x))$$

La restricción se linealiza en el punto medio de la caja.

$$\lambda^* \leftarrow \arg \min \{\text{LP linealizado}\}$$

El programa lineal estima multiplicadores duales para ponderar restricciones.

Mensaje clave

Cada restricción contribuye según su importancia dual, no por igual.

- Se calcula $\mathcal{L}$ con esos pesos sobre la aproximación lineal.
- lsmeas usa $|D_i| \text{mid}(x_i)$ para elegir la variable.
- Si el LP falla o es no acotado, lsmeas cae a smearsum.

lsmeas selecciona en dos fases

Input: caja $x \in \mathbb{R}^n$, Jacobiano intervalar J

Output: índice i^*

```
1 Resolver el LP con la variable objetivo no acotada;  
2 if no hay solución óptima o el óptimo es no acotado then  
3   return decisión de smearsum;  
4 for  $i = 1, \dots, n$  do  
5    $D_i \leftarrow \lambda_i^*$ ;  
6   for  $j = 1, \dots, m$  do  
7      $D_i \leftarrow D_i + J_{ji} \lambda_{n+j}^*$ ;  
8    $s_i \leftarrow |D_i| \text{ wid}(x_i)$ ;  
9 return  $\arg \max_i s_i$ ;
```

Configuración experimental

- Implementamos `lsmeas` y variantes en `IbexOpt`, con `HC4`, `ACID(HC4)` y relajación lineal.
- La selección de nodos usa `FeasibleDiving`; la precisión fija es $\epsilon = 10^{-6}$.
- Evaluamos 76 instancias de `COCONUT`, corridas cinco veces por estrategia.
- Reportamos el promedio tras eliminar el mejor y el peor tiempo por instancia.

lsmeas supera a las estrategias clásicas

Estrategia	Mejora media relativa	Tiempo total (s)
rr	2.04	21 035
lf	2.48	19 181
smax	1.34	20 429
ssum	1.30	19 181
ssr	1.32	20 429

- lsmeas logra la mejor mejora media relativa frente a las cinco referencias.
- Casi 90% de las instancias se resuelven en menos de dos veces el mejor tiempo.
- En la muestra, ssum obtiene el mejor tiempo total entre las estrategias clásicas.

lsmear lidera en tiempo en varias instancias

Instancia	lsmear	lsmear-MG	lsmear-LR
hs087	0.6 s, 65 nodos	0.6 s, 46 nodos	5.7 s, 953 nodos
harker	1071 s	1514 s	3865 s
linear	137 s	25 s	115 s

El mejor tiempo depende de la instancia

- hs087: lsmear y lsmear-MG empatan en tiempo.
- harker: lsmear es más rápido.
- linear: lsmear-MG es más rápido.

lsmear-LR queda sistemáticamente detrás

- Pierde en tiempo frente a las otras dos variantes.
- Usa muchas más cajas en hs087 y harker.

lsmear-MG es la mejor variante práctica

Desempeño global

- lsmear-MG, lsmear y lsmear-LR muestran el mejor rendimiento.
- lsmear-LI y lsmear-LRI reportan los peores resultados.
- ssum-active apenas mejora frente a ssum.

Ganancia media de lsmear-MG

1.07 (lsmear), 1.05 (lsmear-LR), 2.25 (lsmear-LI)

1.43 (lsmear-LRI), 1.42 (ssum-active), 1.43 (ssum)

Mide cuánto supera lsmear-MG a cada estrategia de referencia.

Elección recomendada

lsmear-MG se prefiere por simplicidad y porque evita modificar el contructor.

FeasibleDiving mejora el tiempo promedio

Estrategia	ssum	ssumrel	lsmeas-MG	Ganancia
minLB	59,274	76,392	29,136	2.03
FeasibleDiving	43,867	65,789	19,181	2.29

- FeasibleDiving supera a minLB en las tres estrategias de selección.
- lsmeas-MG supera a ssum y ssumrel con ambas búsquedas.
- 19,181 es el tiempo total de lsmeas-MG con FeasibleDiving.

Idea

- lsmeas estima pesos con una linealización de Taylor y *multipliers* duales óptimos.
- Usa esa estimación para ponderar las restricciones en la función lagrangiana local.

Mensaje clave

- lsmeas y lsmeas-MG mejoran a ViolationTransfer.
- lsmeas-MG es más simple de implementar: no modifica el *contractor*.
- El costo del LP es pequeño frente al *pruning* del solver.

lsmeas mejora el branching sin intrusión

Idea central

lsmeas pondera las restricciones con los multiplicadores óptimos de una linealización y calcula un smear tipo Lagrangiano.

- lsmeas y lsmeas-MG superan todas las estrategias clásicas de bisección.
- lsmeas-MG usa las restricciones originales para medir el impacto de las variables.
- Frente a lsmeas-LRI, mejora el cálculo del impacto tras obtener los valores duales.
- A diferencia de ViolationTransfer, no modifica el contractor ni la estrategia global.
- Futuro: incorporar errores de violación y evaluar variables ligadas solo a restricciones lineales.