

lsmeas: selección de variables con multiplicadores lagrangianos

Journal of Global Optimization, 2017

Ignacio Araya y Bertrand Neveu

Introducción

Propuesta

Experimentos

Conclusiones

Introducción

branch-and-bound usa variables informadas

Idea central

Cada nodo es una caja; la bisección separa una variable y construye el árbol.

Contexto del solver

- La optimización global continua se resuelve determinísticamente con `interval branch and bound`.
- La estrategia de ramificación influye en el rendimiento del solver.
- `round-robin` y `largest-first` no usan información del sistema.

Limitación

Una mala elección puede multiplicar cajas y retrasar la convergencia.

smear agrega impactos en toda la restricción

smear-based

- Usa derivadas intervalares y anchos de variables.
- `smearsum`, `smearmax` y `smearsumrel` agregan impactos.
- También incluyen la función objetivo en la agregación.

Limitación

- La agregación es global y no distingue restricciones por su contribución local.
- La decisión puede perder sensibilidad a la factibilidad.
- Al bisecar, el impacto se redistribuye entre subproblemas.

Propuesta

lsmeas pondera restricciones con duales óptimos

Idea central

$$g_j(x) \approx g_j(\text{mid}(x)) + \text{mid}(J_{j.})(x - \text{mid}(x))$$

La linealización de Taylor se construye alrededor del punto medio de la caja.

$$L(x, \lambda^*) = f(x) + \sum_{j=1}^m \lambda_j^* g_j(x)$$

- Se resuelve el programa lineal y se obtienen los **duales óptimos** λ^* .
- Luego, el smear evalúa el impacto ponderado de cada variable sobre L .
- La variable elegida maximiza ese impacto ponderado.

La linealización produce una sensibilidad ponderada

Aproximación lineal en la caja actual

$$g_j(x) \approx g_j(\text{mid}(x)) + J_{j\cdot} (x - \text{mid}(x))$$

$$D_i = \lambda_i^* + \sum_{j=1}^m \lambda_{n+j}^* J_{ji}$$

- J_{ji} sobreestima $\partial g_j / \partial x_i$ en la caja actual.
- $|D_i| \text{wid}(x_i)$ mide el impacto de la variable x_i .
- Si el LP falla, `smearsum` selecciona la siguiente variable.

lsmeas separa linealización y selección

Input: caja actual x , Jacobiano intervalar J

Output: índice i^* de la variable elegida

- 1 resolver un LP sobre x , con la variable objetivo no acotada;
 - 2 *if el LP no tiene solución o es no acotado then*
 - 3 | lanzar smearsum con el mismo J ;
 - 4 obtener multiplicadores duales óptimos λ^* ;
 - 5 **foreach** x_i **do**
 - 6 | calcular D_i con J_i y λ^* ;
 - 7 | medir $\text{smear}(x_i, g_j) = |D_i \cdot \text{wid}(x_i)|$;
 - 8 **return** $\arg \max_i \text{smear}(x_i, g_j)$;
-

Idea clave

La fase global usa el LP; la fase local calcula el impacto y elige la variable con mayor smear.

Cuatro variantes separan cálculo e impacto

Linealización

- `lsmear-MG` usa el gradiente en el punto medio.
- Requiere dos gradientes: uno para linealizar y otro para el impacto.
- `lsmear-LI` sustituye J_{ji} por $\text{mid}(J_{ji})$.

Relajación lineal

- `lsmear-LR` usa la relajación lineal de Ibex.
- `lsmear-LRI` calcula el impacto con esa misma relajación.
- Ambas requieren adaptar el contratista para obtener los duales.

Experimentos

El experimento usa IbexOpt y COCONUT

Configuración experimental

`lsmeas` y sus variantes se implementan en `IbexOpt` con HC4, ACID(HC4) y relajación lineal.

- Búsqueda con `FeasibleDiving` y precisión $\epsilon = 10^{-6}$.
- Se evalúan 76 instancias de COCONUT, series 1 y 2.
- Cada estrategia se ejecuta cinco veces por instancia.
- Se reporta el promedio de tres corridas, descartando mejor y peor.

lsmeat supera a las estrategias clásicas

Comparación	Ganancia media de lsmeat
rr	2.04
lf	2.48
smax	1.34
ssum	1.30
ssr	1.32

- lf obtiene los peores resultados entre las estrategias clásicas.
- ssum, smax y ssr rinden de forma comparable.
- lsmeat resuelve casi 90% de instancias en menos del doble del mejor tiempo.

lsmeas-MG y lsmeas-LR lideran entre variantes

Variante	Tiempo medio	Boxes	Ganancia media
lsmeas	21,035	–	0.91
lsmeas-MG	19,181	–	1.07
lsmeas-LR	20,429	–	0.94

- lsmeas-MG, lsmeas-LR y lsmeas muestran el mejor desempeño global.
- lsmeas-LI y lsmeas-LRI quedan claramente por detrás.
- lsmeas-MG es preferible: mejora lsmeas-LR y simplifica la implementación.

Mensaje clave

La variante lsmeas-MG lidera sin modificar el contractor del solver.

lsmear-MG domina en tiempo total

Instancia	minLB				FeasibleDiving			
	ssum	ssr	MG	gan.	ssum	ssr	MG	gan.
ex7_2_9	20	to	34	0.59	14	to	16	0.85
himmel16	110	163	31	3.51	26	32	41	0.65
linear	321	335	36	9.03	214	226	25	8.43
batch	365	436	92	3.96	105	98	55	1.78
total time	59 274	76 392	29 136	2.03	43 867	65 789	19 181	2.29

- FeasibleDiving supera a minLB con cualquier selección de variables.
- lsmear-MG mejora a ssum en 1.63 con minLB.
- lsmear-MG mejora a ssum en 1.43 con FeasibleDiving.
- El mejor tiempo total lo obtiene lsmear-MG con FeasibleDiving.

Conclusiones

Heurística

lsmeas pondera las restricciones con multiplicadores duales óptimos de una linealización.

- Calcula el smear de una función tipo Lagrangiano.
- **La linealización** permite obtener los multiplicadores duales.
- lsmeas-MG usa las restricciones originales para medir los impactos.
- **lsmeas-MG** supera a lsmeas-LRI en rendimiento.
- Futuro: incorporar la violación de restricciones en la ponderación.